

Veri Madenciliđi

Dr. Deniz Demirciođlu Diren

Veri Madenciliği İş Adımları



Veri madenciliği adımları, genellikle CRISP-DM (Çapraz Endüstri Standart Süreci) çerçevesine dayandırılır.

İş Problemi ni Anlama

“Veriden ne öğrenmek isteniliyor?”

- Tahmin mi yapılacak?
- Sınıflandırma mı?
- Kümeleme mi?
- İlişki çıkarımı mı?

Örnek:

- Öğrencinin başarı durumu tahmin edilecek mi?
- Bir makalenin kabul edilme olasılığı mı?

Veriyi Tanımak

Veri Nedir?

Çalışmalarda veri;

kayıt,
örnek,
girdi,
gözlem,
durum

olarak da isimlendirilebilir.

Bir durum ile ilgili özellikleri belirten nitelikler ve gözlemleri ifade eden nesnelerden oluşmaktadır.

Kısaca, nesneler yani gözlemler ve nesnelere ait niteliklerden oluşan kümedir.





Veriyi Tanımak



Veri Nasıl Toplanır?

- Gözlem
- Anket
- Mülakat birebir görüşme
- Deney
- Ölçüm
- Veri paylaşım siteleri
- Veri tabanları kayıtları

Veriyi Tanımak


- Kaç gözlem, kaç değişken?
- Eksik veri var mı?
- Aykırı değerler?
- Değişken türleri (sayısal, kategorik)

Nesneler

Nitelikler

Tid	Geri Ödeme	Medeni Durum	Gelir	Dolanıcı
1	Evet	Bekar	125K	Hayır
2	Hayır	Evli	100K	Hayır
3	Hayır	Bekar	70K	Hayır
4	Evet	Evli	120K	Hayır
5	Hayır	Boşanmış	95K	Evet
6	Hayır	Evli	60K	Hayır
7	Evet	Boşanmış	220K	Hayır
8	Hayır	Bekar	85K	Evet
9	Hayır	Evli	75K	Hayır
10	Hayır	Bekar	90K	Evet

Veriyi Tanımak



Veri türü, hangi istatistiksel yöntemin ve hangi veri madenciliği algoritmasının kullanabileceğini belirler.

Veriyi Tanımak

Çeşitli yöntemlerle topladığımız ya da ulaştığımız veriyi bir analiz için kullanmadan önce onunla ilgili fikir sahibi olmalıyız.

Bu veriyi uygun şekilde analiz edebilmeye hazırlayabilmek için önemlidir.

Önce veriyi tanımalıyız.

Veriyi tanımak için;

- Verinin dağılım özellikleri
- Merkezi eğilimi
- Veri türlerini
- Verideki gürültü ve kirlilikleri

incelemek gereklidir.



Veriyi Tanımak



Gürültülü ve Kirli Veri


Nedir?

- Tekrarlı veriler
- Tutarsız veriler
- Eksik veriler
- Uyumsuz veriler

Hazırlık: Veri Önişleme

- Veri ile çalışırken yapılan analiz sonuçlarının kaliteli ve güvenilir olması için verinin de kaliteli olması gereklidir.
- Çoğunlukla veri elde edildiği ilk ham hali ile kullanım ve analiz için uygun değildir.
- Bu nedenle öncelikle veri hazırlanarak analiz için uygun hale getirilmelidir.
- Hazırlık işlemlerini kapsayan sürece de veri





Veri Önışleme

Önemi

Veri madenciliğini makine ve yapay zekadan ayıran en temel adım veri önışlemedir.

Veri madenciliğinin en önemli unsurudur. Veri madenciliğinin büyük bir kısmı veri önışlemeden meydana gelir, en önemli katkı bu aşamada olur.

Verilerin içerisinde mutlaka eksik, hatalı veriler mevcuttur. Bunları bazı istatistiksel yöntemler ve veri ön işleme adımları düzenlemek oldukça önemlidir.

Veri Ön İşlemede Kontrol Edilecek Hususlar



Kesinlik: Veride belirsizlik olup olmadığı, verilerin net şekilde belirtilip belirtilmediğidir



Tamamlık: Tüm niteliklerde tüm değerlerin eksiksiz olarak girilip girilmediğidir.



Tutarlılık: Çelişkili verilerin olup olmaması. Farklı veri kaynaklarından veriler birleştirildiğinde bu konuya dikkat edilmelidir.

Veri Ön İşlemede Kontrol Edilecek Hususlar



Güncellik: Veriler güncel olmalıdır.



İnandırıcılık: Verilerde şüpheyne neden olacak bir durum yani diğer verilerden ya da geçmiş verilerden çok farklı olmamalıdır.



Yorumlanabilirlik: Veriler kolayca anlaşılabilir olmalıdır.

Veri Önişleme adımları

Veri Temizleme

Veri Birleştirme

Veri
Dö nü ş türme

Veri Azaltma

Veri Temizleme

Veri seti içerisindeki,

1. Aykırı değerlerin tespit edilmesi
2. Hatalı verinin düzeltilmesi
3. Eksik verilerin ortadan kaldırılması veya tamamlanması
4. Tutarsızlıkları giderme

işlemleridir.

Veri temizleme işlemleri sayesinde verideki gürültü azaltılmış olur.

Veri Temizlem e

- o Verinin eksik olması Ör: Bir örneğin yaş değerinin girilmemiş olması
- o Verinin gürültülü olması: Ör: Yaşın negatif ya da 500 gibi bir değer girilmesi
- o Tutarsız veri: Ör: Doğum tarihi ile yaş verisi birbirine uygun değil
- o Ya da kasıtlı olarak boş da bırakılmış olabilir.

Bu durumların çözülmesi gerekmektedir.

Veri Temizlem e

Veri temizleme için ayrı ayrı yöntem ve teknikler

geliştirilmiştir. Bunlar;

- o İstatistiksel yöntemler
- o Kümeleme
- o Optimizasyon
- o Regresyon

olabilir.

Veri temizlem e için çözüm yöntemle ri

1. Temizlenmesi gereken verileri silmek

Bu veri madenciliğinde çok istenen bir çözüm değildir. Çünkü önemli veriler kaybedilebilir. Veriyi kazanıp işlemek önemlidir. Çözüm olarak aşağıdaki işlemler yapılabilir.

- Eğer veriye ulaşabiliyorsak manuel olarak düzeltilerek tekrar doldurulabilir
- Hatalı ve eksik verileri birtakım yöntemlerle doldurmak

Veri temizlem e için çözüm yöntemle ri

2. Ortalama ile tamamlama:

En sık kullanılan çok kullanılan yöntemdir. Bu durum istatistiksel dağılımı etkilemez o nedenle algoritmalarda soruna neden olmaz.

Bu çözüm veriyi ihmal etmekten daha iyidir.

3. Sınıflandırma yapılarak tamamlama:

Bu çözüm yönteminde mevcut veriler değerlere göre sınıflandırılır ve eksik veri bu sınıflardan hangisine uygunsa ona göre tamamlanır.

Örneğin yaş bilgisi eksik bunu eğitim durumuna göre sınıflandırırız. Lisede ise şu yaş grubu Üniversite işe şu yaş grubu gibi

Veri temizleme için çözüm yöntemleri

3. Bayesian ya da karar ağacı algoritması ile tamamlama:

- Veri setinde Tek bir grup değil Yaş, meslek kıdemi, meslek, maaş gibi birden fazla grup olabilir.
- Bu durumda çeşitli kriterlere göre kişileri gruplandırılır. Örneğin araba verisi; model, marka, km ye göre fiyat eksik bilgiyi tamamlarız
- 5 yıllık Kia Marka 50.000 km de arabalara göre bu özellikteki bir arabanın fiyat bilgisi tamamlanabilir.
- Yani aslında bu çözümde özelliğe göre bir değer atanmaktadır. Ortalama değer ya da sınıflandırmaya göre daha iyidir.

Veri temizlem e için çözüm yöntemle ri

4. Kutulama (binning) algoritması;

- Bu yöntemde veriler sıralanır ardından sıralanan veri üzerinde eşit boyutlar şeklinde kutulama yapılır. Örneğin yaşa göre, 30-40 aralığında 100 kişi var, 40-50 yaş aralığında 100 kişi var;
- Eksik olan verinin örneği hangi grupta kaldıysa mean, medyan ya da boundary yöntemi ile ortalama alınıp atanır.
- Boundary sınır değeridir buna göre hatalı ya da eksik verinin yerine o sınıftaki en yüksek ya da düşük değer atanabilir.

Veri temizlem e için çözüm yöntemle ri


5. Regresyon

- Veriler bir doğru üzerinde yerleşir. Eksik verileri bu doğru etrafında tahmin ederek tamamlanabilir.
- Gürültülü verileri temizlemek için tercih edilir.

Veri temizle me için çözüm yönteml eri

6 .Kümeleme

- Verileri benzerliklerine göre gruplar eksik veri hangi gruba daha yakınsa eksik veri o gruba göre tamamlanır. Gürültülü verileri temizlemek için tercih edilir.
- Eğer veri hiçbir kümeye ait değilse bu veri aykırı veridir ve silmek faydalı olacaktır.



Veri
temizlem
e için
çözüm
yöntemle
ri

7. Eğri Uydurma

- Bu yöntem verinin bir fonksiyona uydurulması temeline dayanmaktadır.
- Doğrusal eğri uydurma ile bir değişkenin değeri diğer bir değişken kullanılarak elde edilebilir.

Veri Birleşti rme

- Bazı durumlarda farklı veri kaynaklarından ya da veri tabanlarından tek bir yerde toplanarak birleştirilebilir.
- Bu durumda veri kayıpları, yanlış eşleştirmeler olabilir. Aynı nitelik farklı kodlanmış ya da farklı metrikler kullanılmış olabilir
- Niteliklerdeki bu gibi tutarsızlıklar detaylı şekilde incelenerek düzeltilmelidir.
- Ayrıca farklı veri kaynaklarından verilerin birleştirilmesi gereksiz verilerin kaydedilmesine neden olabilir.

Veri Dönüşümü

- Veri setinde, analizde ya da sonrasındaki yorumlamalar aşamasında kullanım için anlamlı gözükmeyen nitelikler bulunabilir. Bu durum veri setini ham halinde de olabilir veri birleştirme gibi bir işlem sonucunda da ortaya çıkmış olabilir.
- Örneğin iki veri seti birleştirilirken bir veri setinde yaş bilgisi varken diğer veri setinde bu bilgi doğum yılı olarak girilmiş olabilir.
- Ya da bir nitelik veri tip açısından kullanılacak analiz yöntemine uygun olmayabilir.
- Bunun gibi durumlarda veriler üzerinde uygun Veri Dönüşümü işlemi yapılmalıdır.

Veri Dönüşümü

Veri Dönüşümü için kullanılabilecek
çözümler;

➤Veri düzeltme

- Kutulama
- Kümeleme
- Eğ ri Uydurma

➤Normalizasyon

➤Nitelik oluş turma

Veri Düzeltilme

Veri setindeki hatalı, uyumsuz
veya biçimsel olarak yanlış
girilmiş değerlerin analiz
öncesinde uygun hâle
getirilmesidir.

Amaç, verinin anlamını
bozmadan doğruluğu ve
tutarlılığı artırmaktır.

Veri Düzeltilme

Örnek ;

- Değer aralığı kontrolü (örn. yaş < 0 ise düzeltilir/eksik kabul edilir)
- Birim standardizasyonu (cm–m, kg–g)
- Yazım/kod standardizasyonu (Türkiye / Turkiye → “Türkiye”)
- Tarih formatlarının tekleştirilmesi (01.02.2026 → 2026-02-01)

Veri Düzeltme

Kutulama, sürekli sayısal değerleri belirli aralıklara ayırarak daha düzenli temsil etmektir.

Amaç: gürültüyü azaltmak ve bazı analizleri kolaylaştırmaktır.

Örnek: Yaş →

0-18 (Genç), 19-35 (Genç yetişkin), 36-60 (Yetişkin), 60+ (Yaşlı)

Veri Düzeltme

Kümeleme, benzer gözlemleri gruplandırarak veriyi daha anlamlı yapılar hâlinde temsil etmektir.

Amaç: örüntüleri görmek, gruplara göre analiz yapmak veya bazı değerleri grup temelli düzeltmektir.

Örnek: Müşteriler → “düşük harcama / orta harcama / yüksek harcama” kümeleri

Veri Düzeltme

Eğri uydurma, değişkenler arasındaki ilişkiyi bir fonksiyonla (doğrusal, polinom vb.) modelleyerek veriyi daha iyi temsil etmektir.

Amaç: trendi yakalamak, gürültüyü azaltmak veya bazı değerleri tahmini olarak düzenlemektir.

Örnek: Zaman–satış verisine doğrusal trend uydurmak

Normalizasyon

Normalizasyon, sayısal değişkenlerin belirli bir ölçeğe dönüştürülmesi işlemidir.

Amaç, farklı büyüklüklerdeki değişkenlerin analiz ve modelleme sürecine eşit katkı sağlamasını temin etmektir.

Özellikle uzaklık temelli algoritmalarda ve optimizasyon süreçlerinde normalizasyon kritik öneme sahiptir.

Normalizasyon Neden Gereklidir?

Değişkenler farklı ölçeklerde olabilir
(ör. yaş: 18–80, gelir: 5.000–100.000)

Büyük ölçekli değişkenler modeli baskılayabilir

Bazı algoritmalar ölçekten doğrudan etkilenir

Normalizasyon yapılmadığında, model sonuçları yanıltıcı olabilir.

Min–Max Normalizasyonu

Min–Max normalizasyonu, verileri belirli bir aralığa (genellikle 0–1) dönüştürür.

Formül:
$$x' = \frac{x - x_{min}}{x_{max} - x_{min}}$$

Bu yöntem, verinin dağılım yapısını koruyarak ölçeklendirme yapar.

Min–Max Normalizasyonu Örneği

Bir veri setinde yaş değişkeni:

- Minimum yaş = 20
- Maksimum yaş = 60
- İncelenen değer = 40

$$x' = \frac{40 - 20}{60 - 20} = \frac{20}{40} = 0,5$$

Bu işlem sonucunda yaş değeri **0–1 aralığına taşınmış olur.**

Z-Score Normalizasyonu (Standartlaştırma)

Z-score normalizasyonu, verileri ortalamaya göre merkezler ve standart sapmaya böler.

Formül:

$$z = \frac{x - \mu}{\sigma}$$

Bu yöntem, özellikle normal dağılıma yakın verilerde tercih edilir.

Z-Score Normalizasyonu Örneği

Bir veri setinde:

- Ortalama (μ) = 50
- Standart sapma (σ) = 10
- İncelenen değer = 60

$$z = \frac{60 - 50}{10} = 1$$

Bu sonuç, değer in ortalamasının 1 standart sapma üzerinde olduğunu gösterir.

Ondalık Normalizasyon

Ondalık normalizasyon, değerlerin virgöl kaydırılarak küçültülmesi esasına dayanır.

Amaç, tüm değerleri **-1 ile 1** aralığına yaklaştırmaktır.

Bu yöntem daha basit ve hızlıdır, ancak dağılım bilgisini dikkate almaz.

Ondalık Normalizasyo n Örneği

Bir veri setinde en büyük değer 987 ise:

- Uygun bölme katsayısı = 1000

$$x' = \frac{x}{1000}$$

Örneğin:

- $450 \rightarrow 0,45$
- $987 \rightarrow 0,987$

Veri Dönüşümü

- Nitelik Oluşturma
- Bu yöntem yeni nitelikler oluşturarak veri setine ekleme temeline dayanmaktadır.
- Ancak bu yöntemi kullanırken dikkat edilmesi gereken hususlar vardır.
 - 1. Oluşturulan yeni nitelik mevcut niteliklerden daha önemli bilgiler içermeli
 - 2. Analiz sonuçlarındaki başarıyı olumlu yönde etkilemeli

Veri Dönüşümü Örnek

•Mevcut nitelikler: **Boy, Kilo**

Yeni nitelik: **$VKI = Kilo / Boy^2$**

Yaş → Yaş Grubu (Yeni nitelik)

•Mevcut nitelik: **Yaş**

•Yeni nitelik: **Yaş_Grubu**

•0-18: Genç

•19-35: Genç Yetişkin

•36-60: Yetişkin

•60+: Yaşlı

Veri Azaltma

olduğunda analiz için kullanılan makine öğrenme algoritmalarının çözüm üretme süresi uzamaktadır.

- Gereksiz verileri veri setinde azaltarak temizlemek bazen başarı üzerinde de olumlu etkilere neden olmaktadır.
- Kısacası, veri setinin özet forma sokulduğu veri azaltma ve indirgeme işlemleri hem başarı hem de çalışma süresi açısından fayda sağlamaktadır.

Örnek :

1.000.000 satır ve 200 değişken içeren bir veri setinde model eğitimi çok uzun sürmektedir.

Bu durumda amaç, veriyi **temsil gücünü koruyarak** daha küçük ve yönetilebilir hâle getirmektir.

Veri Azaltma

Veri azaltma için kullanılan bazı yöntemler bulunmaktadır;

- Nitelik birleştirme
- Nitelik azaltma
- Veri sıkıştırma
- Veri ayrıştırma
- Veri küçültme

Nitelik Birleştirme

- Mevcut: Vize, Final

- Yeni: $\text{Dönem_Notu} = 0,4 \cdot \text{Vize} + 0,6 \cdot \text{Final}$

Amaç: İki değişkeni tek bir daha anlamlı değişkende birleştirmek.

Nitelik Azaltma

- Mevcut: 200 değişken

- Seçim sonrası: En anlamlı 20 değişken

Örnek yöntemler: korelasyonu çok yüksek değişkenlerden birini çıkarma / önem düzeyine göre seçim

Amaç: Gereksiz veya tekrar eden değişkenleri azaltmak.

Veri Sıkıştırma

- Metin verisi: 50.000 kelimelik içerik
- Sıkıştırılmış temsil: Gömme (embedding) ile daha kompakt gösterim

Amaç: Veriyi saklama ve işleme maliyetini düşürmek

Veri Ayırıştırma (Boyut İndirgeme Mantığı)

- Çok sayıda değişken yerine daha az sayıda bileşen ile temsil
- Örnek: 100 değişken $\rightarrow$ 10 bileşen

Amaç: Bilgiyi kaybetmeden daha düşük boyutlu temsil elde etmek.

Veri Küçültme (Örnekleme)

- 1.000.000 satır yerine temsil edici 100.000 satır ile çalışma

Amaç: Hesaplama süresini azaltmak.

Not: Örnekleme “temsil edici” yapılmazsa model performansı düşebilir.